

Proyecto final integrador

Analítica de datos a gran escala y benchmarking experimental

Maestría en Inteligencia Artificial — Asignatura: Big Data — Universidad de Palermo

Ficha técnica del proyecto

- **Dataset oficial:** US Accidents (2016 - 2023), disponible en Kaggle (<https://www.kaggle.com/datasets/sobhanmoosavi/us-accidents>). Registra ~ 7.7 millones de siniestros viales continuos en Estados Unidos con 46 atributos espacio-temporales, climáticos y de infraestructura (~ 3.0 GB en formato plano CSV).
- **Modalidad:** Grupal (7 grupos de trabajo conformados en la asignatura).
- **Desafío central:** Cada grupo deberá implementar y responder **5 consultas analíticas** bajo dos tecnologías contrastantes (Pandas vs. PySpark) con benchmarking experimental, y además formular, resolver y justificar la **Consigna 6: Modelado de machine learning a escala con Spark MLlib** (eligiendo y justificando un único paradigma entre clasificación, regresión o clusterización).
- **Entregables obligatorios:**
 1. **Artículo científico (paper):** Redactado en la plantilla institucional Formato_Investigadores.doc.
 2. **Presentación para defensa oral:** Diapositivas en formato PDF/PowerPoint de **máximo 10 slides**.
 3. **Código fuente reproducible:** Enlace público accesible (Google Drive o repositorio GitHub) a los notebooks/scripts con instrucciones claras de ejecución.

1. Objetivos del proyecto final

El objetivo principal es evaluar experimentalmente los límites del procesamiento mononodo frente a las ventajas del cómputo distribuido sobre un volumen masivo de datos:

- **Resolución analítica:** Responder consultas de agregación, filtrado temporal, análisis geográfico y relaciones multivariadas sobre datos a escala real.
- **Benchmarking experimental:** Medir y comparar tiempos de ejecución reales (*wall-clock time*), documentar consumo de memoria y analizar cuellos de botella computacionales.
- **Modelado con Spark MLlib:** Diseñar y entrenar un pipeline de machine learning distribuido con `pyspark.ml` (clasificación, regresión o clusterización), justificando la formulación del problema, la preparación de variables y la evaluación de métricas.
- **Justificación técnica:** Argumentar los resultados a partir de los conceptos arquitecturales vistos en clase: particionado, evaluación perezosa (*lazy evaluation*), optimización del plan de ejecución (*Catalyst*) y gestión de memoria (*Project Tungsten*).

2. Catálogo general de consultas

A continuación se detalla el conjunto de las 10 consultas diseñadas para el proyecto. Cada grupo deberá responder el lote de 5 consultas asignado en la Sección 3.

Consulta 1: Filtro temporal y distribución horaria: Filtrar los siniestros ocurridos entre dos marcas temporales de alto volumen (ej. entre 2021-01-01 y 2022-12-31). Analizar y graficar la distribución horaria (0 a 23 horas) de dichos eventos, identificando las horas pico.

Consulta 2: Condiciones más comunes en los accidentes: Determinar la combinación contextual y meteorológica más frecuente: franja horaria (Mañana, Tarde, Noche), clima (`Weather-Condition`), visibilidad y señalización vial (`Traffic_Signal` o `Junction`).

- Consulta 3: Búsqueda espacial por radio dado un punto:** Dado un punto geográfico (Lat_0, Lng_0) y un radio R en kilómetros (ej. 25 km), filtrar los accidentes dentro del área mediante la distancia de Haversine: $d = 2r \arcsin \left(\sqrt{\sin^2(\frac{\Delta\phi}{2}) + \cos(\phi_1) \cos(\phi_2) \sin^2(\frac{\Delta\lambda}{2})} \right)$, con $r = 6371$ km, ordenados por proximidad.
- Consulta 4: Hotspots espaciales: top 5 puntos más peligrosos [común a todos los grupos]:** Identificar y reportar las **5 coordenadas geográficas más peligrosas** (a nivel nacional o en un estado de alto flujo como California o Texas) dado un radio geográfico de influencia (ej. $R = 2.0$ km o 5.0 km). El equipo debe definir formalmente el criterio de peligrosidad (densidad absoluta, concentración de accidentes con $Severity \geq 3$, o índice ponderado) y justificar el método espacial implementado.
- Consulta 5: Distancia y duración promedio inicio–fin:** Calcular la distancia geográfica promedio entre el inicio (Start_Lat, Start_Lng) y el fin (End_Lat, End_Lng), junto con la duración promedio (End_Time – Start_Time), desglosado por nivel de severidad (Severity).
- Consulta 6: Ranking de autopistas críticas y tiempo de despeje:** Normalizar las vías de la columna Street (ej. *I-95*, *I-5*, *US-101*) para elaborar el Top 10 de autopistas con mayor índice de siniestros graves ($Severity \geq 3$) y reportar su tiempo promedio de despeje vial.
- Consulta 7: Matriz de impacto de infraestructura vial en la severidad:** Evaluar la influencia de elementos viales (como Crossing, Junction, Railway, Roundabout, Stop o Traffic_Signal) sobre la gravedad del siniestro, comparando la severidad media ante presencia vs. ausencia.
- Consulta 8: Detección de días con anomalías meteorológicas severas:** Detectar días y estados donde los siniestros superaron en más de 3 desviaciones estándar ($> 3\sigma$) la media histórica del estado, cruzando con variables climáticas (Precipitation, Wind_Speed, Visibility) para corroborar eventos extremos.
- Consulta 9: Top 10 intersecciones más críticas por procesamiento de texto:** Analizar el texto de Street y Description para aislar siniestros en cruces viales (patrones como “and”, “&”, “corner”) y rankear las 10 esquinas con mayor siniestralidad acumulada.
- Consulta 10: Velocidad de despeje según iluminación y tipo de día:** Comparar el tiempo medio de despeje (End_Time–Start_Time) en condiciones diurnas versus nocturnas (Sunrise_Sunset, Astronomical_Twilight), contrastando días hábiles con fines de semana.

3. Asignación de consultas por grupo

Cada grupo responderá **5 consultas**: la Consulta 4 (común a todos los grupos) y 4 consultas asignadas según la siguiente matriz:

Grupo	Consulta obligatoria	Consulta A	Consulta B	Consulta C	Consulta D
Grupo 1	Consulta 4 (Hotspots)	Consulta 1	Consulta 2	Consulta 6	Consulta 7
Grupo 2	Consulta 4 (Hotspots)	Consulta 2	Consulta 3	Consulta 5	Consulta 8
Grupo 3	Consulta 4 (Hotspots)	Consulta 1	Consulta 5	Consulta 9	Consulta 10
Grupo 4	Consulta 4 (Hotspots)	Consulta 3	Consulta 6	Consulta 8	Consulta 10
Grupo 5	Consulta 4 (Hotspots)	Consulta 1	Consulta 3	Consulta 7	Consulta 9
Grupo 6	Consulta 4 (Hotspots)	Consulta 2	Consulta 5	Consulta 6	Consulta 8
Grupo 7	Consulta 4 (Hotspots)	Consulta 3	Consulta 5	Consulta 7	Consulta 10

✓ Pautas para el benchmarking comparativo de las 5 consultas

- Para cada una de las 5 consultas, registrar el tiempo neto de ejecución (*wall-clock time*) en Pandas y en PySpark.
- En PySpark, invocar una acción terminal (`.count()`, `.collect()` o similar) para materializar el grafo de cómputo y medir la ejecución real.
- En Pandas, si alguna operación agota la memoria RAM física (*Out Of Memory*), documentar el punto de fallo, el tamaño del objeto involucrado y el comportamiento del sistema.
- Calcular el factor de aceleración: $\text{Speedup} = \frac{T_{\text{Pandas}}}{T_{\text{Spark}}}$.

4. Consigna 6: Machine learning a escala con Spark MLlib [común a todos los grupos]

Además de las 5 consultas analíticas, cada grupo formulará, implementará y evaluará la **Consigna 6**, consistente en resolver **un único problema de machine learning** utilizando la biblioteca distribuida `pyspark.ml`. La definición concreta del problema, la hipótesis de trabajo y las variables seleccionadas quedan a criterio y propuesta del equipo, debiendo justificar exhaustivamente sus decisiones.

Cada grupo elegirá **solo una** de las siguientes tres alternativas:

- **Opción A — Clasificación supervisada:** Formular un problema predictivo categórico (por ejemplo, predicción de severidad alta $\text{Severity} \geq 3$ versus severidad normal, o probabilidad de corte prolongado de calzada) a partir de atributos climáticos, temporales y de infraestructura. Modelos sugeridos: `LogisticRegression`, `RandomForestClassifier` o `GBClassifier`. Métricas requeridas: ROC-AUC, exactitud (*accuracy*) y/o F1-score sobre conjunto de prueba (*test*).
- **Opción B — Regresión supervisada:** Formular un problema predictivo continuo (por ejemplo, estimación de la duración del accidente en minutos $\text{End_Time} - \text{Start_Time}$, o distancia del tramo vial congestionado) en función de variables contextuales y meteorológicas. Modelos sugeridos: `LinearRegression`, `RandomForestRegressor` o `GBRegressor`. Métricas requeridas: RMSE, MAE y R^2 sobre conjunto de prueba.
- **Opción C — Clusterización no supervisada:** Descubrir perfiles latentes de siniestralidad vial mediante segmentación multidimensional (por ejemplo, agrupación espacial y climática de siniestros para caracterizar tipologías de zonas de riesgo). Modelos sugeridos: `KMeans` o `BisectingKMeans`. Métrica requerida: Coeficiente de Silueta (*Silhouette*) con `ClusteringEvaluator`, justificando la selección del número de clústeres k .

Requisitos metodológicos obligatorios para la Consigna 6:

1. **Justificación del problema:** Explicar la motivación analítica de la variable objetivo o de las dimensiones seleccionadas.
2. **Pipeline de ingeniería de características:** Emplear componentes de `pyspark.ml` (`VectorAssembler`, manejo de nulos, indexado con `StringIndexer` y/o escalado con `StandardScaler` si aplica).
3. **Entrenamiento y validación:** Partición rigurosa de datos (ej. 80 % train / 20 % test para supervisado) o barrido de hiperparámetros (para no supervisado).
4. **Interpretación de resultados:** Analizar las métricas obtenidas y contrastar si el modelo confirma la hipótesis inicial.

5. Estructura requerida para el artículo científico

El informe final debe entregarse en formato de artículo académico utilizando estrictamente la plantilla institucional `Formato_Investigadores.doc`. El artículo contendrá las siguientes secciones:

1. **Título, autores y resumen (abstract):** Síntesis concisa (150 a 250 palabras) del objetivo, datos analizados, metodología de benchmarking, modelo de ML aplicado y principales conclusiones cuantitativas.
2. **Introducción:** Contexto del análisis masivo de datos viales, problemática del escalamiento y motivación de la comparación de arquitecturas mononodo vs. distribuidas.
3. **Desarrollo metodológico:**
 - **Datos y preprocesamiento:** Descripción del dataset, variables utilizadas, decisiones de almacenamiento y transformaciones previas.
 - **Entorno de cómputo:** Especificación detallada del hardware empleado (modelo de CPU, cantidad de núcleos físicos/lógicos, memoria RAM instalada, sistema operativo y versiones de software).
 - **Acceso al código: Enlace público obligatorio (Google Drive o GitHub)** con los scripts o notebooks ejecutables y debidamente comentados.
4. **Resultados analíticos:** Exposición clara y estructurada de las 5 consultas asignadas, complementada con tablas y gráficos representativos.
5. **Modelado con Spark MLlib (Consigna 6):** Justificación del problema elegido (clasificación, regresión o clusterización), formulación de la hipótesis, arquitectura del pipeline, resultados de entrenamiento y discusión de métricas.
6. **Evaluación experimental de rendimiento:** Tabla comparativa de tiempos de ejecución (Pandas vs. PySpark en las 5 consultas), cálculo de Speedup y discusión técnica de los cuellos de botella y ventajas observadas.
7. **Conclusiones:** Conclusiones técnicas fundamentadas sobre cuándo y por qué utilizar cada tecnología y lecciones de arquitectura.
8. **Referencias bibliográficas:** Documentación técnica y fuentes de referencia académica consultadas.

6. Presentación y defensa oral

Durante la sesión de cierre, cada equipo defenderá su trabajo ante el docente:

- **Límite de diapositivas: Máximo 10 slides.**
- **Estructura recomendada:**
 - Slide 1: Portada (grupo, integrantes, título).
 - Slide 2: Dataset, arquitectura y especificaciones del entorno de cómputo.
 - Slides 3 a 5: Consultas analíticas asignadas (síntesis de las 5 consultas, destacando C4 y los principales hallazgos).
 - Slide 6: Consigna 6: Planteo del problema de machine learning (justificación, paradigma elegido y pipeline).
 - Slide 7: Consigna 6: Resultados experimentales, métricas y evaluación del modelo.
 - Slide 8: Tabla de benchmarking (Pandas vs. Spark) y discusión del Speedup.
 - Slide 9: Conclusiones técnicas y lecciones de arquitectura.
 - Slide 10: Cierre y espacio para preguntas del docente.
- **Tiempo de exposición:** 12 minutos de presentación grupal + 3 minutos de preguntas del docente.