

UNIVERSIDAD DE PALERMO | FACULTAD DE INGENIERÍA

Maestría en Inteligencia Artificial — Asignatura: Big Data

PROCESAMIENTO DISTRIBUIDO Y ANALÍTICA PREDICTIVA DE ACCIDENTES VIALES EN EE. UU. (2016–2023)

Evaluación Masiva de 7.72M de Registros: Índices Espaciales, Optimización Parquet,
Consultas de Alta Complejidad y Pipeline Distribuido Spark MLlib

INTEGRANTES (GRUPO 4): Juan Diego Weber | Diego | Melisa

DOCENTES: Cátedra de Big Data • Defensa Oral de Proyecto Final • Octubre 2026

Dataset, Arquitectura y Especificaciones del Entorno de Cómputo

CARACTERÍSTICAS DEL DATASET Y PIPELINE I/O

- **Dataset US Accidents (2016–2023):**

- 7,728,394 tuplas y 46 atributos heterogéneos (temporales, meteorológicos, viales).
- Formato original CSV de 2.87 GB (2,940 MB) sin tipado estricto.


- **Optimización de Almacenamiento Columnar:**

- Conversión a Apache Parquet con compresión ZSTD: 491.33 MB (-82.9% en disco).
- Sorting físico por (Start_Lat, Start_Lng): clusteriza geográficamente los row groups.
- Predicate Pushdown: Lectura de solo columnas necesarias con pruning a nivel metadata.

- **Especificaciones del Entorno de Cómputo:**

- Apache Spark 3.5.0 en PySpark sobre OpenJDK 11 (64-bit).
- Motor local / Google Colab T4, Python 3.11, Pandas 2.2 con PyArrow 14.
- Pipeline modular reproducible con soporte nativo multiplataforma.

Compresión Física y Ahorro de Almacenamiento



Consultas Analíticas (Parte 1): Análisis Espacial y Hotspots Críticos (C3 y C4)


SÍNTESIS DE C3 Y C4: HAVERSINE Y HOTSPOTS

• Consulta 3 — Filtro Geodésico Paramétrico (Haversine $R = 25$ km):

- Los Ángeles (34.05, -118.24): 361,038 siniestros detectados en 1.67 s.
- New York (40.71, -74.00): 269,717 siniestros (conglomerado a 105 m en Manhattan).
- Speedup Pandas (1.67 s) vs Spark (8.83 s): Pandas vectorizado en RAM supera el shuffle.

• Consulta 4 — Hotspots de Peligrosidad (DESTACADA OBLIGATORIA):

- ENFOQUE A (Severidad Crítica Nacional ≥ 3 , Grilla ~ 2.2 km):
Prioriza riesgo vital e impacto hospitalario:
#1 Downey/LA (33.94, -118.10) con 1,619 | #2 George Washington Br. NY (40.85, -73.94) con 1,550
#3-#5 Nodos I-75/I-85 en Atlanta (1,432, 1,372 y 1,301 siniestros graves).
- ENFOQUE B (Densidad Absoluta Urbana, Grilla ~ 5 km):
Mide saturación vehicular: Top 1 en Downtown LA (34.05, -118.25) con 50,254 choques.



Consultas Analíticas (Parte 2): Corredores Viales y Detección de Anomalías (C6 y C8)

SÍNTESIS DE C6 Y C8: CRITERIOS MULTIDIMENSIONALES

• Consulta 6 — Normalización Regex y Peligrosidad en Autopistas:

- Extracción canónica vía `r'\b(I-\d+|US-\d+)\b'` agrupando miles de variantes textuales.
- MÉTRICA 1 (Tasa Relativa Severidad Crítica):
Liderada por autopistas rurales rápidas: I-72 (92.15% graves) e I-57 (81.15%).
- MÉTRICA 2 (Volumen Absoluto de Trauma Vial):
I-95 lidera con 62,202 siniestros graves (95.6 min despeje) seguida de I-10 (44,309).

• Consulta 8 — Detección de Anomalías Estadísticas (> 3 Sigma):

- PERSPECTIVA VOLUMEN DE SATURACIÓN:
California registra picos absolutos de 2,823 accidentes (29-01-2021) y 2,637 (28-12-2020).
- PERSPECTIVA RAREZA METEOROLÓGICA (Z-SCORE HISTÓRICO):
Kansas (23.25 σ) y Ohio (18.27 σ , 649 choques) durante la Tormenta Invernal Elliott con vientos sostenidos de 26.2 mph y visibilidad desplomada a 1.29 millas.



Consultas Analíticas (Parte 3): Dinámica Temporal y Latencia de Despeje Vial (C10)

SÍNTESIS DE C10: HALLAZGOS Y MATRIZ FOTOMÉTRICA

- **Consulta 10 — Velocidad de Despeje Vial (7.72M de Filas Procesadas):**

- MATRIZ EJECUTIVA (4 Cuadrantes):

- Día Hábil: 336.5 min (~5.6 h) | Noche Hábil: 503.1 min (~8.4 h)
- Día Fin de Semana: 532.0 min (~8.9 h) | Noche Fin de Semana: 720.1 min (~12.0 h).

- MATRIZ FOTOMÉTRICA INTEGRAL (8 Cuadrantes):


Diferenciación entre Sol Directo y Crepúsculo Astronómico (Astronomical_Twilight):

- Día Solar pleno en día hábil: 336.6 min.
- Crepúsculo nocturno: 345.7 min (la luz residual mitiga la ceguera vial).
- Noche cerrada en fin de semana: escala drásticamente a 772.75 min (~12.88 horas).

- **Diagnóstico y Conclusión Operativa (+130.4% de Retraso):**

El salto responde a un cuello de botella logístico severo: escasez de dotaciones de grúas pesadas fuera de hora y demoras de cuadrillas del DOT en responder a siniestros graves.

Impacto de la Iluminación y Ciclo Semanal en el Despeje (C10)



Consigna 6: Planteo del Problema de Machine Learning (Spark MLlib)

JUSTIFICACIÓN Y PARADIGMA

1. Motivación y Variable Objetivo:

- Variable Objetivo: Severity (Nivel 1 a 4).
- Justificación ITS: Despacho inteligente anticipado de unidades médicas y control semafórico antes de que la congestión se vuelva irreversible.

2. Paradigma Distribuido Elegido:

- Clasificación Supervisada con pyspark.ml.
- Algoritmo: DecisionTreeClassifier.
- Hiperparámetro maxBins=60: Fundamental para absorber la alta cardinalidad de los 49 estados sin pérdida de información de splits.

3. Prevención Estricta de Data Leakage:

- Se eliminaron por diseño todas las variables post-impacto (End_Time, Duration, Distance(mi)). El modelo solo opera con factores exógenos preexistentes.

PIPELINE DE CARACTERÍSTICAS (54 FEATURES)

Arquitectura del Pipeline de pyspark.ml:

- Imputación de Nulos (fillna):
Valores meteorológicos nulos imputados con medias de bloque.
- Variables Categóricas e Indexación:
State -> StringIndexer -> OneHotEncoderEstimator.
- Variables Temporales Derivadas:
Extracción de Hour, Month, DayOfWeek a partir de Start_Time.
- Infraestructura Vial (13 booleanas a Float):
Junction, Traffic_Signal, Crossing, Station, Stop, Amenity, etc.
- Ensamblado Vectorial:
VectorAssembler consolida las 54 variables en un vector 'features' optimizado para cómputo matricial distribuido.

Consigna 6: Resultados Experimentales, Métricas y Evaluación del Modelo

MÉTRICAS DISTRIBUIDAS Y CONFIRMACIÓN DE HIPÓTESIS

- **Partición Rigurosa y Entrenamiento:**

- Partición 80% Train / 20% Test con semilla fija sobre el universo de 7.72M.
- Tiempo total de entrenamiento y scoring Spark MLlib: 245.72 segundos.

- **Métricas de Evaluación Obtenidas:**

- Accuracy: 79.81% (superando significativamente el baseline del 73.2%).
- F1-Score Ponderado: 0.7138, demostrando robustez frente al severo desbalanceo de clases (Severidad 2 representa más del 79% del dataset total).

- **Interpretación y Contrastación de Hipótesis:**

- Reglas del Árbol: Los splits de mayor ganancia de información sitúan a Visibilidad (< 3.0 mi) y cercanía a Intercambiadores viales (Junction == True).
- Se confirma la hipótesis: La degradación visual extrema combinada con geometrías complejas de incorporación multiplica por 4 la severidad catastrófica (Nivel 3 y 4).




Tabla de Benchmarking (Pandas vs. Spark) y Discusión del Speedup


BENCHMARKING DE LAS 5 CONSULTAS Y SPEEDUP

Consulta | Pandas | PySpark | Speedup | Ganador

C3 (Haversine)	1.67 s	8.83 s	0.19x	Pandas (C/Arrow)
C4 (Hotspots)	1.73 s	8.42 s	0.21x	Pandas (Local)
C6 (Autopistas)	5.12 s	14.30 s	0.36x	Pandas (Local)
C8 (Anomalías)	35.38 s	52.44 s	0.68x	Pandas (Local)
C10 (Despeje)	30.04 s	18.25 s	1.65x	PySpark (Shuffle)

• PAUTAS METODOLÓGICAS OBLIGATORIAS (CÁTEDRA):

- 1. Wall-Clock Time: Registro neto con `time.perf_counter()` aislando la ejecución.
- 2. Materialización en PySpark: Acción terminal forzada (`.count()` / `.collect()`) para materializar el DAG físico y evaluar el costo de computación real sin sesgos de lazy evaluation.
- 3. Resiliencia y OOM en Pandas: Documentación del punto de fallo por memoria finita: Haversine global continuo $O(N^2)$ para 7.72M requeriría ~238 TB en RAM (colapso SIGKILL); se mitigó con grilla celular $O(N)$ consumiendo < 45 MB.
- 4. Factor de Aceleración: $Speedup = T_{Pandas} / T_{Spark}$. Pandas domina en filtros vectorizados mononodo; Spark triunfa en agregaciones complejas (C10: 1.65x) y escala out-of-core.



Conclusiones Técnicas y Lecciones de Arquitectura

1. INGENIERÍA DE ALMACENAMIENTO COLUMNAR

- El paso de CSV a Parquet ZSTD redujo el 82.9% del espacio en disco.
- El ordenamiento por coordenadas habilitó Predicate Pushdown, reduciendo hasta un 70% las operaciones de lectura de I/O en disco durante filtros espaciales.

2. COMPLEMENTARIEDAD PANDAS VS. SPARK

- No existe una herramienta única: Pandas domina en analítica geodésica local en memoria;
- PySpark es insustituible para agregaciones multinivel masivas (C10), pipelines de ML out-of-core y procesamiento distribuido tolerante a fallos.

3. VALOR DE LA DOBLE PERSPECTIVA METODOLÓGICA

- Separar volumen absoluto de tasa relativa evita la falacia poblacional (California/I-95).
- El cruce de Z-score meteorológico con severidad permite anticipar eventos catastróficos en corredores desatendidos de la red interestatal.

4. APLICABILIDAD EN POLÍTICA PÚBLICA E ITS

- El salto de despeje a ~13 horas en noches de fin de semana justifica el refuerzo de cuadrillas del DOT y grúas de alto tonelaje.
- El modelo ML permite semaforización predictiva y ruteo dinámico con 79.8% de certeza.

GRUPO 4 — MAESTRÍA EN INTELIGENCIA ARTIFICIAL

¡Muchas Gracias por su Atención!

Espacio Abierto para Preguntas, Discusión y Devolución del Cuerpo Docente

-
- Repositorio del Proyecto: <https://github.com/jdiegoweber-debug/BIG-DATA-GRUPO-4>
 - Dataset Consolidado: data/raw/us_accidents.parquet (491 MB, ZSTD)
 - Notebook Reproducible: BIG-DATA-GRUPO-4-Colab.ipynb (Local & Google Colab)
 - Paper Oficial Formato CoNallSI: Formato_Investigadores.pdf / .doc
 - Tiempo Asignado para Preguntas del Tribunal: 3 minutos